



Informe técnico de arquitectura e implementación para un agente conversacional serverless

recap-agent

Sin Envolturas

30 de septiembre de 2026

Resumen

Este informe describe la arquitectura y la implementación de *recap-agent*, un agente conversacional serverless para Sin Envolturas. El sistema mantiene un plan de evento con varias necesidades de proveedores, recupera información del marketplace y ejecuta acciones sujetas a autorización. La implementación separa la interpretación y la generación de lenguaje, realizadas por el LLM, de la validación determinista de identidad, estado y efectos. La verificación determinista obtuvo un 100% de aprobación en 1 482 comprobaciones ejecutadas. La última evaluación dirigida en desarrollo obtuvo un 100% en siete interacciones seleccionadas y en sus 47 condiciones objetivas. Estos indicadores corresponden a los escenarios y al entorno evaluados; no representan una tasa de éxito entre usuarios de producción.

Alcance y evidencia

El documento cubre planificación, información autorizada del cliente, generación conversacional, ejecución de acciones, persistencia, observabilidad, despliegue y resultados de validación. La evidencia corresponde al repositorio y a los registros de implementación y evaluación disponibles hasta el 30 de septiembre de 2026 en América/Lima. El informe actualiza la entrega parcial de junio; los documentos y resultados anteriores se conservan como registros históricos.

Registro de versiones

v1.0	2026-06-22	Arquitectura de la entrega parcial, proveedores, conocimiento y despliegue en desarrollo.
v2.0	2026-09-30	Arquitectura y evidencia operativa hasta el 29 de septiembre.
v2.1	2026-09-30	Validación dirigida y consolidación documental.
v2.2	2026-09-30	Informe en español con redacción técnica descriptiva y términos especializados conservados.
v2.3	2026-09-30	Presentación de resultados medidos y cobertura funcional.



Índice

1	Propósito y sistema implementado	4
2	Arquitectura y procesamiento de turnos	4
2.1	Componentes	4
2.2	Secuencia observable	5
3	Conversación, planes y contexto	6
4	Información del cliente y control de acceso	7
4.1	Perfil autorizado completo	7
4.2	Consultas de información	7
5	Invitaciones, acciones y hora registrada	7
6	Proveedores, conocimiento y cierre	8
7	Persistencia, observabilidad y despliegue	8
8	Resultados de validación y cobertura funcional	9
8.1	Indicadores de aprobación	9
8.2	Cobertura funcional	9
8.3	Interpretación de los resultados	10
9	Discusión y limitaciones	10



1 Propósito y sistema implementado

La planificación de un evento suele comenzar con una solicitud incompleta. Un mismo evento puede requerir fotografía, catering y otros servicios, cada uno con restricciones y estados de selección distintos. *recap-agent* representa estas necesidades en un plan persistente y las vincula con registros de proveedores de Sin Envolturas. El plan permite conservar una selección mientras se precisa o resuelve otra necesidad.

El alcance implementado también comprende consultas públicas y de cuenta, pedidos y regalos, invitaciones, confirmación de asistencia, autenticación y soporte. Estas tareas comparten el procesamiento de turnos y el estado persistente, pero mantienen las restricciones de acceso y las condiciones de ejecución propias de cada fuente y acción.

El runtime es independiente del canal. La integración con WhatsApp corresponde a un adaptador externo que verifica webhooks, obtiene la identidad confiable del remitente, deduplica entregas y envía la respuesta generada. El cliente de terminal invoca la Lambda de desarrollo y reproduce el comportamiento del canal sin streaming. El despliegue del runtime, por sí solo, no verifica el funcionamiento del adaptador externo.

El LLM interpreta tareas estructuradas y genera las respuestas. El código determinista valida schemas, identidad, autorización, estado establecido, condiciones de ejecución y recibos de acciones. Cada oración entregada al cliente se genera en el turno correspondiente; el runtime no inserta respuestas predefinidas ni modifica el texto generado para imponer un resultado.

2 Arquitectura y procesamiento de turnos

2.1 Componentes

AWS Lambda recibe la solicitud HTTP normalizada y valida el token de aplicación. La Function URL proporciona transporte HTTPS; la autorización del cliente se valida dentro de la aplicación. El handler comprueba la solicitud, asigna un identificador de correlación y delega el procesamiento al servicio conversacional. Los módulos de dominio mantienen planes y evidencia tipada. Los gateways encapsulan las APIs de Sin Envolturas y la recuperación semántica.

DynamoDB almacena planes, coordinación de turnos, recibos de efectos y registros de desempeño. Secrets Manager administra credenciales y CloudWatch conserva diagnósticos operativos protegidos. CloudFormation define recursos separados para desarrollo y producción [2, 3, 4, 1]. La Figura 1 presenta los componentes físicos y sus conexiones.




Figura 1: Arquitectura física del sistema: canales, runtime serverless, OpenAI y fuentes de Sin Envolturas. Los contratos descritos en el informe delimitan la responsabilidad de cada componente.

2.2 Secuencia observable

Cada turno valida la solicitud, carga y coordina el plan, prepara las fuentes autorizadas y extrae tareas estructuradas. Luego valida el estado y las condiciones de ejecución, realiza las lecturas y acciones permitidas, genera una respuesta a partir de la evidencia y persiste el estado y la telemetría. La clasificación de entrega se conserva en las rutas donde corresponde.




Figura 2: Procesamiento de un turno: preparación de evidencia autorizada, validación tipada, ejecución y generación de la respuesta.

3 Conversación, planes y contexto

El plan de evento es el principal registro persistente. Almacena identidad del usuario y canal, estado del plan, tipo y ubicación del evento, presupuesto, escala, preferencias, restricciones, contexto pendiente y datos de contacto. Cada necesidad de proveedor tiene su propio estado y selección. Incorporar catering no elimina al fotógrafo seleccionado; cerrar necesidades listas no obliga a enviar aquellas que permanecen pendientes.

La extracción estructurada propone tareas y acciones. El runtime no determina la intención mediante keywords o coincidencias exactas de texto. La validación determinista conserva entidades ya establecidas, comprueba fechas y números extraídos y verifica las condiciones de los efectos. La evidencia contiene hechos, procedencia, datos faltantes, alternativas sin resolver y resultados reales, en lugar de respuestas preescritas.

Los prompts conversacionales en español se versionan en **prompts/**. El compilador de solicitudes selecciona instrucciones, herramientas y módulos de resultado a partir del estado tipado. La telemetría registra los bytes serializados de instrucciones e inputs, incluidos los fallos cuando existe esa información. La selección de instrucciones pertinentes no limita los registros del cliente que este tiene autorización para consultar. El extractor RSVP distingue las decisiones de acompañante expresadas en el turno actual.

La continuidad conserva preguntas pendientes, referencias a eventos y compras respaldadas por las fuentes y archivos relevantes. Las transferencias internas de tareas no se presentan al cliente. La coordinación de turnos y las barreras de escritura evitan que una ejecución tardía sobrescriba un estado posterior. Los recibos distinguen trabajo solicitado, intentado y confirmado. Un recuerdo o agradecimiento no autoriza repetir la autenticación de una consulta de compra que falló anteriormente.



4 Información del cliente y control de acceso

4.1 Perfil autorizado completo

Antes de la extracción, el orquestador de información prepara todas las fuentes autorizadas disponibles: pedidos, compras de regalos, eventos de cuenta o invitado y detalles devueltos de esos eventos. Las rutas, recursos o aspectos seleccionados por el extractor no eliminan registros ni campos. No se aplica truncamiento por antigüedad ni por un número fijo de registros. Las lecturas tienen límites operativos de concurrencia y tiempo; una fuente incompleta se representa de forma explícita, no como un resultado vacío.

El mismo perfil autorizado llega a extracción y respuesta con fuente, alcance de acceso, momento de lectura, estado de completitud o paginación y fallos. Conservar todos los registros devueltos no prueba que el backend haya devuelto el historial completo. Los alcances de cuenta y teléfono confiable permanecen separados; la autorización mediante OTP puede incorporar registros de cuenta sin descartar los del teléfono. Se excluyen secretos de control de acceso y registros fuera de la autorización del solicitante. La negativa a autenticarse bloquea el acceso protegido aunque exista una cuenta en el estado previo.

4.2 Consultas de información

Las tareas de FAQ, eventos asociados, pedidos y regalos pueden coexistir en un turno de solo lectura. Una referencia exacta y autorizada puede identificar una transacción; las alternativas sin resolver conservan su procedencia. Pago, preparación, envío y saldo de cuenta representan hechos distintos. Un fallo parcial de fuente no equivale a ausencia de registros, ni un pago pendiente equivale a aprobación. La divulgación de campos sensibles depende del alcance de acceso y de la referencia establecida.

5 Invitaciones, acciones y hora registrada

La ejecución de RSVP se vincula con la invitación del solicitante y el evento requerido. Los identificadores de evento e invitado, el sentido de la decisión y los recibos se conservan separados durante consulta, selección y escritura. Una solicitud de acompañante rechazada no se presenta como guardada ni altera la asistencia del usuario. El ejecutor verifica el resultado del backend y el estado actualizado antes de representar un efecto como confirmado; una discrepancia entre fuentes se conserva como conflicto.

Una nueva confirmación de asistencia propia no incorpora una decisión anterior de acompañante que quedó sin resolver. Una continuación limitada a seleccionar el evento puede conservar esa decisión existente. El caso live de cinco turnos de Marta verifica una escritura exitosa y ausencia de escrituras en turnos ambiguos, de consulta o referidos a un evento sin coincidencia.

El contrato temporal conserva la fecha y hora local registradas en la fuente. Una zona verificada



del evento describe el lugar sin modificar esa hora; cuando no existe, se conserva el offset explícito o se marca la zona como desconocida. Un valor que contiene solo fecha no genera una hora. Esta semántica está implementada en `src/core/event-local-time.ts`.

La identidad de un remitente internacional se deriva de códigos E.164 validados y evidencia confiable del canal, no del idioma o la ubicación del evento. El identificador de correlación conecta solicitudes del adaptador con Lambda. Los diagnósticos protegidos de payloads malformados registran estructura, longitudes y hashes, sin texto del cliente ni credenciales. La derivación confiable del remitente y la conciliación de mensajes almacenados sin invocación del runtime corresponden al adaptador externo.

6 Proveedores, conocimiento y cierre

Las APIs de Sin Envoladuras proporcionan identidad de proveedores y campos operativos. La recuperación vectorial amplía los candidatos semánticos; el runtime deduplica y enriquece los resultados antes de incorporarlos al contexto del LLM [5]. Las preferencias se mantienen por necesidad de proveedor. Las operaciones de cotización o cierre validan contacto y selección y conservan sus recibos. Una respuesta fluida no demuestra que se haya enviado una solicitud comercial.

El conocimiento de FAQ se sincroniza por una ruta distinta de la recuperación de proveedores. Los pasajes recuperados y sus citas conservan procedencia. Las consultas de comisiones utilizan el artículo aplicable completo y la evidencia de la calculadora oficial cuando está disponible; no incorporan porcentajes fijos ni cálculos de conciliación sin respaldo. Las instrucciones sobre comisiones se cargan para esa tarea tipada. Una imagen no disponible se representa como evidencia faltante; el LLM puede utilizar otros registros autorizados sin afirmar que observó el archivo.

7 Persistencia, observabilidad y despliegue

Las trazas registran decisiones, inputs y resultados de herramientas, tiempos, tokens, fuentes, persistencia y origen del texto entregado. Los diagnósticos de desarrollo se restringen al cliente de diagnóstico; el canal del cliente recibe la respuesta y la decisión de entrega. Los logs operativos evitan mensajes, teléfonos y credenciales en texto claro. Los resultados fallidos o desconocidos permanecen observables.

La infraestructura se define mediante CloudFormation. Las modificaciones se despliegan primero en desarrollo y se vinculan con un artefacto identificable para su validación. Los registros de despliegue conservan la configuración aplicada, la identidad del código y la evidencia operativa. La promoción a producción utiliza un artefacto explícito y conserva una copia para rollback.

El registro de producción del 29 de septiembre de 2026 documenta la promoción del artefacto seleccionado, la configuración de modelos y las comprobaciones operativas posteriores. La



evaluación dirigida más reciente corresponde a un artefacto de desarrollo posterior. Cada resultado se atribuye a su entorno y fecha; la emisión de este informe no implica una nueva promoción.

8 Resultados de validación y cobertura funcional

8.1 Indicadores de aprobación

La evidencia disponible al 30 de septiembre de 2026 distingue la verificación determinista de la evaluación conversacional sobre la Lambda de desarrollo. La primera comprueba reglas de autorización, contratos de datos y operaciones con entradas controladas. La segunda observa interacciones completas sobre el sistema desplegado. La Tabla 1 presenta los resultados con sus denominadores.

Indicador	Resultado	Aprobación
Comprobaciones deterministas ejecutadas	1 482 de 1 482	100%
Interacciones seleccionadas en desarrollo	7 de 7	100%
Condiciones objetivas de esas interacciones	47 de 47	100%

Tabla 1: Resultados registrados en el entorno y alcance evaluados.

Una comprobación determinista omitida no integra el denominador de aprobación. Las verificaciones de tipos y convenciones de código también concluyeron satisfactoriamente. La ejecución conversacional mantuvo la misma identidad de despliegue al inicio y al cierre. Su costo registrado fue de US\$0.025571, correspondiente a OpenAI y Lambda.

8.2 Cobertura funcional

La cobertura se expresa por responsabilidades observables del sistema. No se dispone de un porcentaje medido de cobertura de líneas de código ni de una estimación de éxito sobre la totalidad de las conversaciones posibles. La Tabla 2 describe las dimensiones verificadas y el resultado que se busca preservar.



Dimensión	Comportamiento verificado
Identidad y acceso	Alcance de cuenta, autenticación mediante OTP, aislamiento entre clientes y rechazo del acceso cuando no se acredita autorización.
Acciones	Correspondencia entre solicitud, entidad y operación; confirmación mediante recibos; ausencia de escrituras en consultas y de efectos duplicados.
Información	Conservación de los registros autorizados y su procedencia; concordancia de importes, fechas y estados con las fuentes consultadas.
Resultados incompletos	Distinción entre ausencia de datos, error de consulta, resultado desconocido y operación reintentable, con correlación para seguimiento.
Contratos de integración	Validación de schemas, entradas malformadas, persistencia, trazas y aritmética monetaria.

Tabla 2: Cobertura funcional de la verificación registrada.

Las siete interacciones de desarrollo cubren continuidad de tareas de evento, aceptación de transferencia a soporte para una limitación de envío de regalos, atención de la retirada de un anfitrión, resultados fallidos o desconocidos en la transferencia posterior a OTP, verificación de OTP expresado en palabras y ejecución de RSVP sobre el evento solicitado. Sus condiciones objetivas comprueban autorización, resultados de acciones y ausencia de repeticiones cuando corresponde.

8.3 Interpretación de los resultados

Los porcentajes describen la aprobación de las comprobaciones efectivamente ejecutadas. La cobertura funcional identifica responsabilidades verificadas, mientras que el resultado conversacional se limita a las siete interacciones seleccionadas en desarrollo. Ambos indicadores permiten comprobar hechos y efectos sin exigir una redacción determinada de la respuesta.

9 Discusión y limitaciones

La implementación combina planificación de eventos, información personalizada y acciones verificadas. La separación entre generación de lenguaje y autorización permite comprobar resultados de negocio sin imponer el texto de la respuesta. La conservación del perfil autorizado y la representación explícita de fuentes incompletas distinguen datos ausentes de fallos de lectura. Los recibos permiten diferenciar una afirmación conversacional de una acción confirmada por el backend.

La evidencia corresponde a siete interacciones de desarrollo. Su alcance depende de los datos del marketplace y de la integración del canal; no mide satisfacción de usuarios.



Referencias

- [1] Amazon Web Services. *AWS CloudFormation Documentation*. 2026. URL: <https://docs.aws.amazon.com/cloudformation/> (consultado el 06/22/2026).
- [2] Amazon Web Services. *Creating and managing Lambda function URLs*. 2026. URL: <https://docs.aws.amazon.com/lambda/latest/dg/urls-configuration.html> (consultado el 06/22/2026).
- [3] Amazon Web Services. *What is Amazon DynamoDB?* 2026. URL: <https://docs.aws.amazon.com/amazondynamodb/latest/developerguide/Introduction.html> (consultado el 06/22/2026).
- [4] Amazon Web Services. *What is AWS Secrets Manager?* 2026. URL: <https://docs.aws.amazon.com/secretsmanager/latest/userguide/intro.html> (consultado el 06/22/2026).
- [5] OpenAI. *Retrieval*. 2026. URL: <https://developers.openai.com/api/docs/guides/retrieval> (consultado el 06/22/2026).